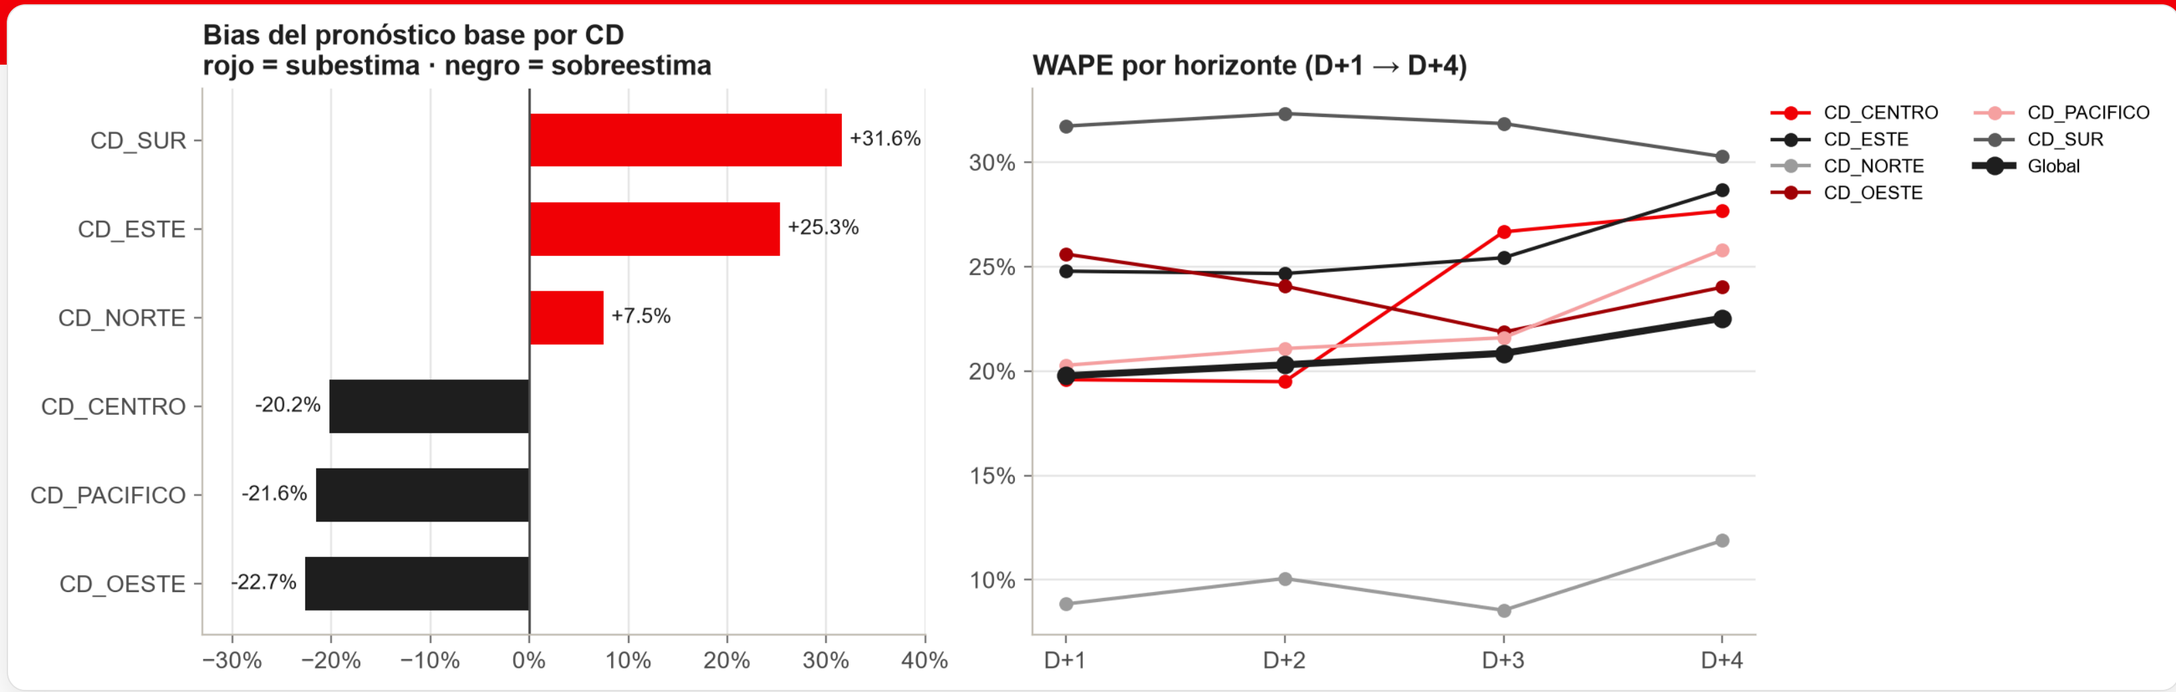
DESAFÍO TÉCNICO · DATA SCIENTIST LEAD · OPTIMIZACIÓN LOGÍSTICA

# El pronóstico base erra un 20.8% (WAPE), y el error es un sesgo sistemático de cada CD

6 CD × 60 días · 1,380 pronósticos D+1…D+4. El bias global (+6.5%) engaña: sesgos de signo opuesto se compensan.



# Tres CD subestiman, tres sobreestiman; el horizonte pesa poco

| CD | Bias | WAPE | Diagnóstico |
|---|---|---|---|
| SUR | +31.6% | 31.6% | Subestima |
| ESTE | +25.3% | 25.9% | Subestima |
| NORTE | +7.5% | 9.8% | Subestima (leve) |
| CENTRO | −20.2% | 23.3% | Sobreestima |
| PACÍFICO | −21.6% | 22.2% | Sobreestima |
| OESTE | −22.7% | 23.9% | Sobreestima |

Bias > 0 = subestimación. El signo se mantiene en el 100% de las semanas en los 6 CD.

WAPE global D+1 → D+4

**19.8% → 22.5%**

+2.8 pp; el salto principal ocurre en D+4. Incluso en D+1 el error es ~20%: el problema es el nivel, no la anticipación.

### Degradación heterogénea

CENTRO (+8 pp) y PACÍFICO (+6 pp) empeoran con el horizonte; en SUR y OESTE el error casi no cambia porque es sesgo puro.

### NORTE: poco error, mucho costo

Es el CD más preciso, pero tiene 6 de los 13 días-CD sobre capacidad.

# El plan sesga volumen y fecha, y los desvíos vuelven al martes

**+10.6%**

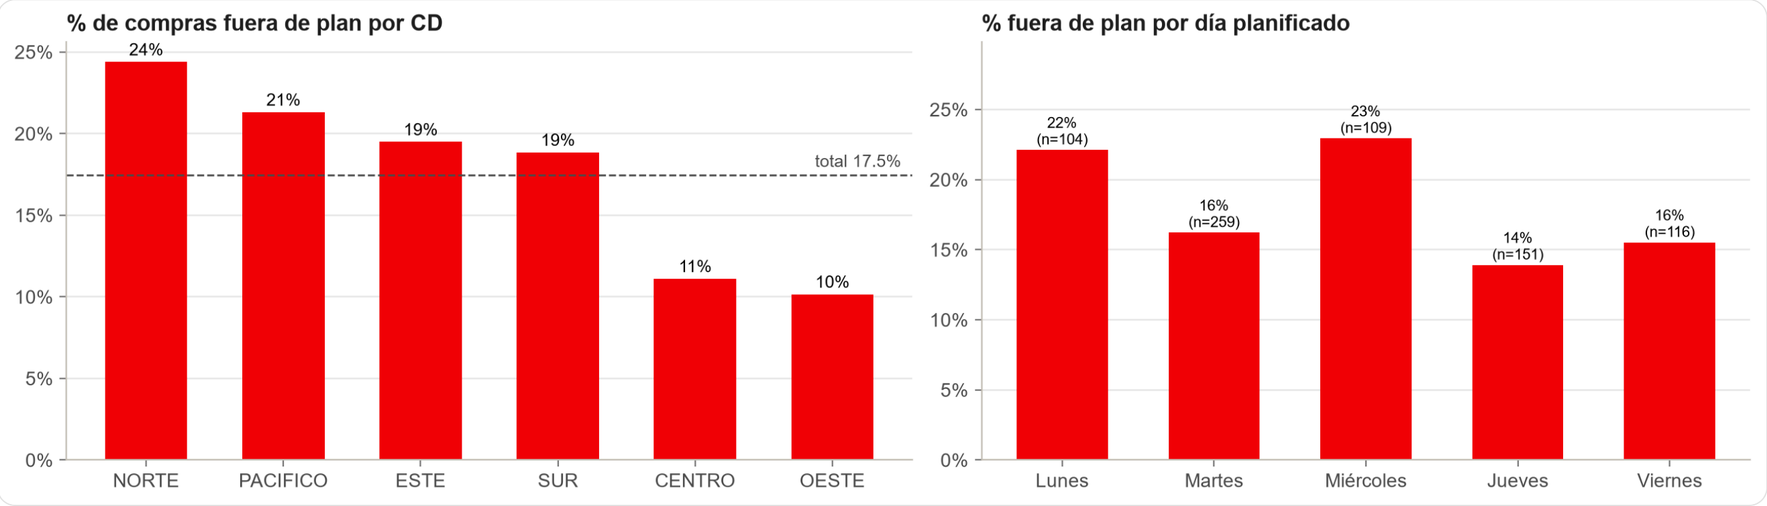
bias de volumen: el plan subestima la compra real (real ≈ 1.12× plan) en los 6 CD y los 3 canales

**17.5%**

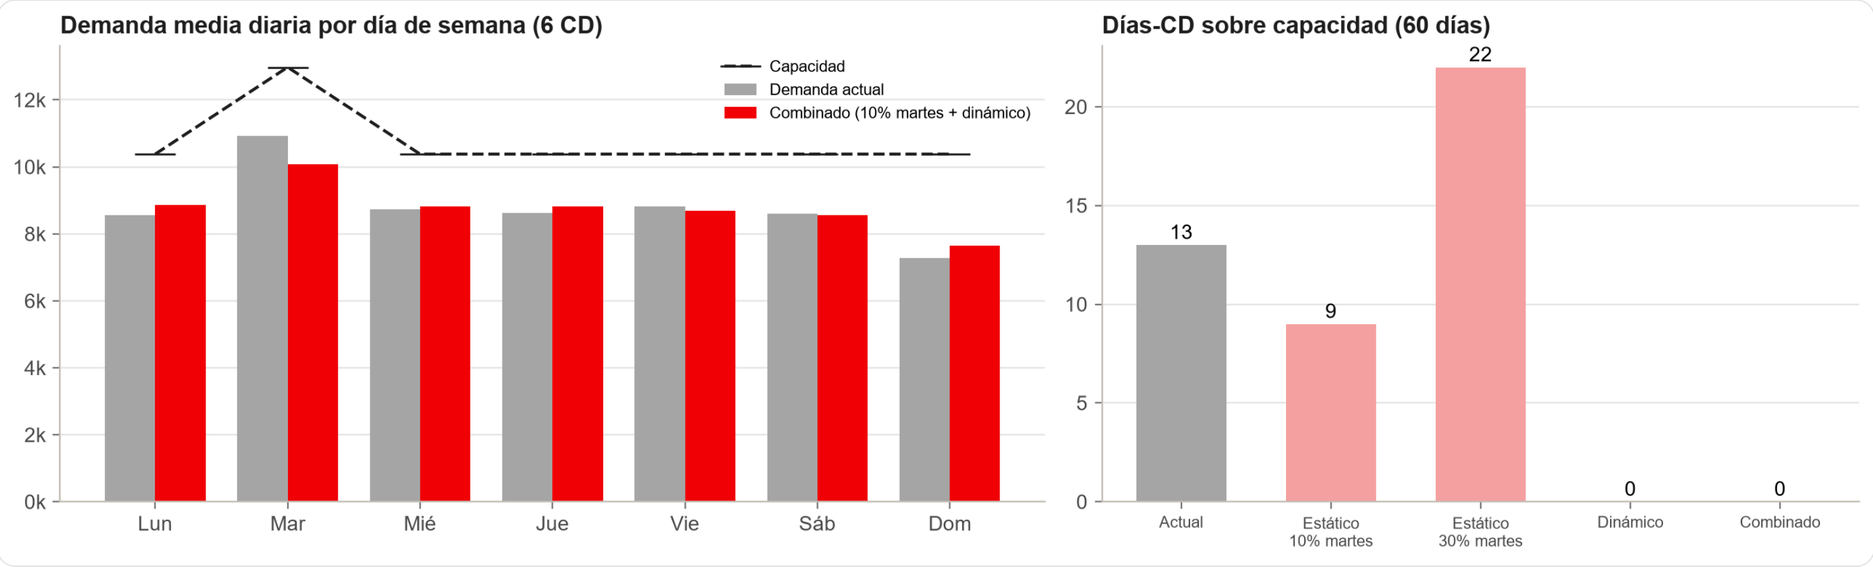
de las compras sale de fecha (129 de 739); los atrasos son 3.5× más frecuentes que los adelantos

**60%**

de las compras fuera de plan termina en martes (77 de 129): el pico se auto-refuerza



# Aplanar con slotting dinámico por utilización




## Mecanismo

Al tomar el pedido: utilización proyectada por slot = pronóstico corregido / capacidad. Se recomienda la fecha con holgura (±2 días), con incentivo si el slot elegido supera 90%.

## Simulación

Dinámico: 13 → 0 días-CD sobre capacidad moviendo 1.6% del volumen. Mover un 30% fijo del martes crea 22. Piloto con los 59 clientes flexibles.

## KPIs (A/B por cliente)

Días-CD sobre capacidad, pico/promedio (hoy 1.24), CV diario, aceptación de la fecha recomendada. Guardarraíl: OTIF y volumen por cliente.

# El modelo aprende la corrección del pronóstico base

### Qué predice

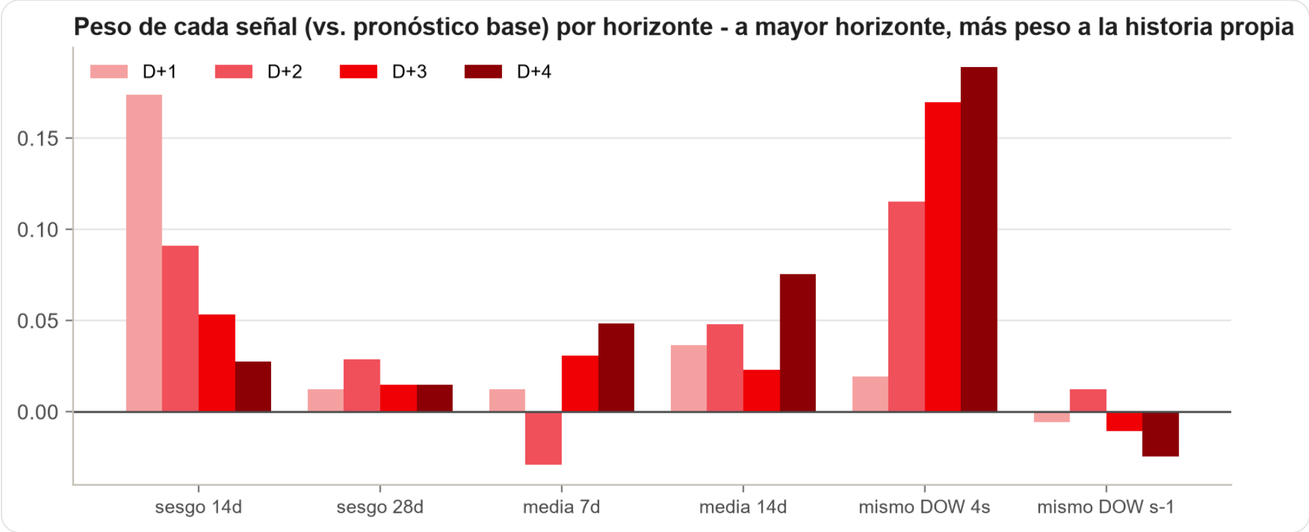
log(real / base), con un Ridge por horizonte, global para los 6 CD y sin ID de CD: transferible a centros nuevos.

### Con qué (solo info hasta E−1)

Día de semana, martes y día pico, índice estacional, medias móviles 7/14d, mismo día 4 semanas, sesgo móvil 14/28d; todo relativo al base, en log.

### Cómo se valida

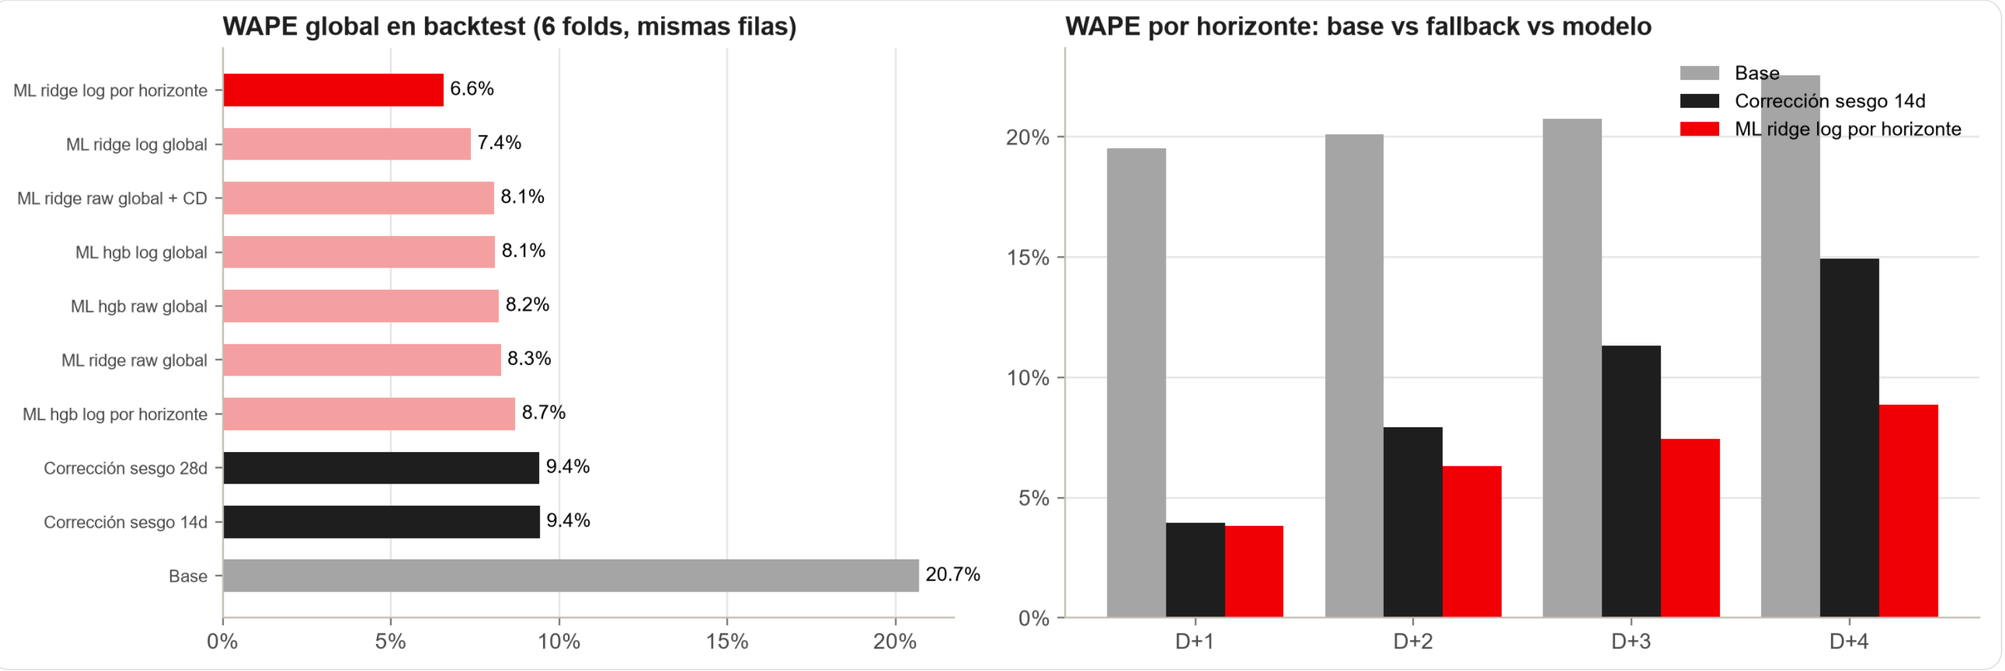
Backtest rolling-origin semanal (6 folds), re-entrenando en cada origen, mismas filas para todos los modelos y bootstrap por semanas.




**A mayor horizonte, más peso a la historia propia: en D+1 manda el sesgo reciente; en D+4, el patrón del mismo día de semana.**

Iteración documentada: v1 (features en niveles, modelo global) → v2 (log-relativas, por horizonte).

# WAPE 20.7% → 6.6% en backtest: 68% menos error

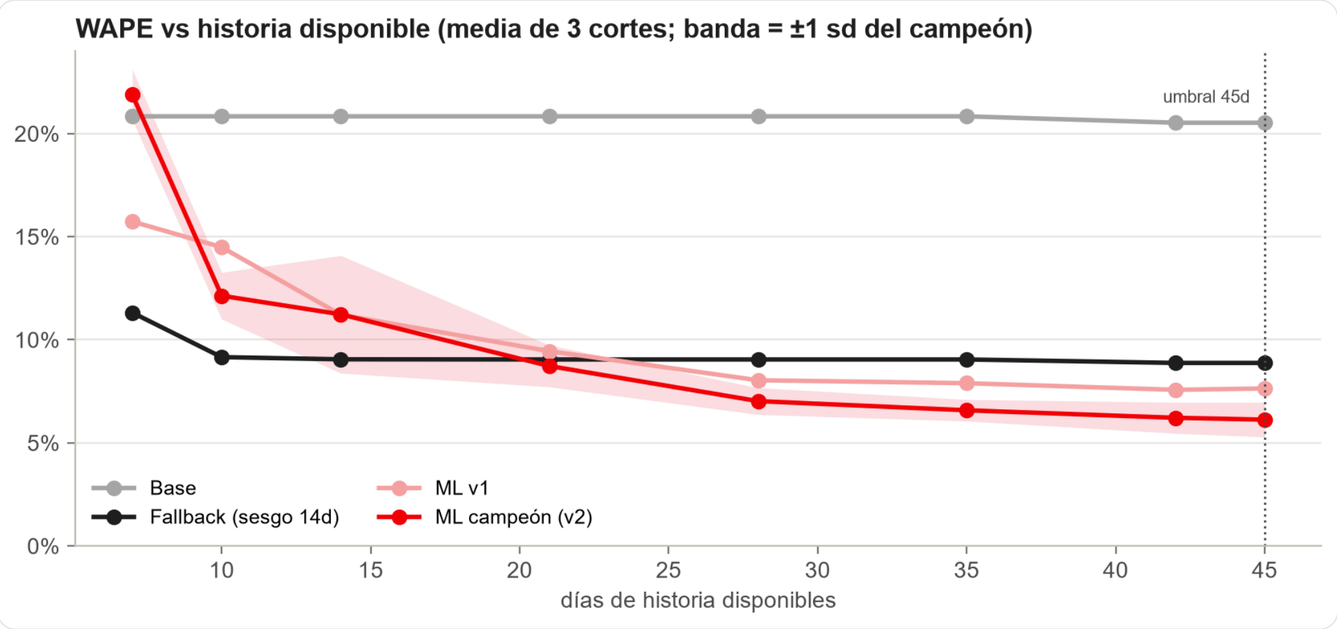



**6/6 folds**
mejor que el base y que el fallback

**Bias en ±2.5%**
en todos los CD (base: −22% a +31%)

**−2.8 pp vs regla simple**
IC95% [−3.4, −2.2]; sobre todo en D+3/D+4

# Gate de 45 días: activar el modelo solo con historia




Simulación: todos los CD truncados a L días; media de 3 fechas de corte.

## Regla

≥ 45 días continuos: modelo. Si no: sesgo móvil 14d o, sin historia, base. Nunca lanza excepción (probado con CD nuevo, huecos y datos corruptos).

## Evidencia

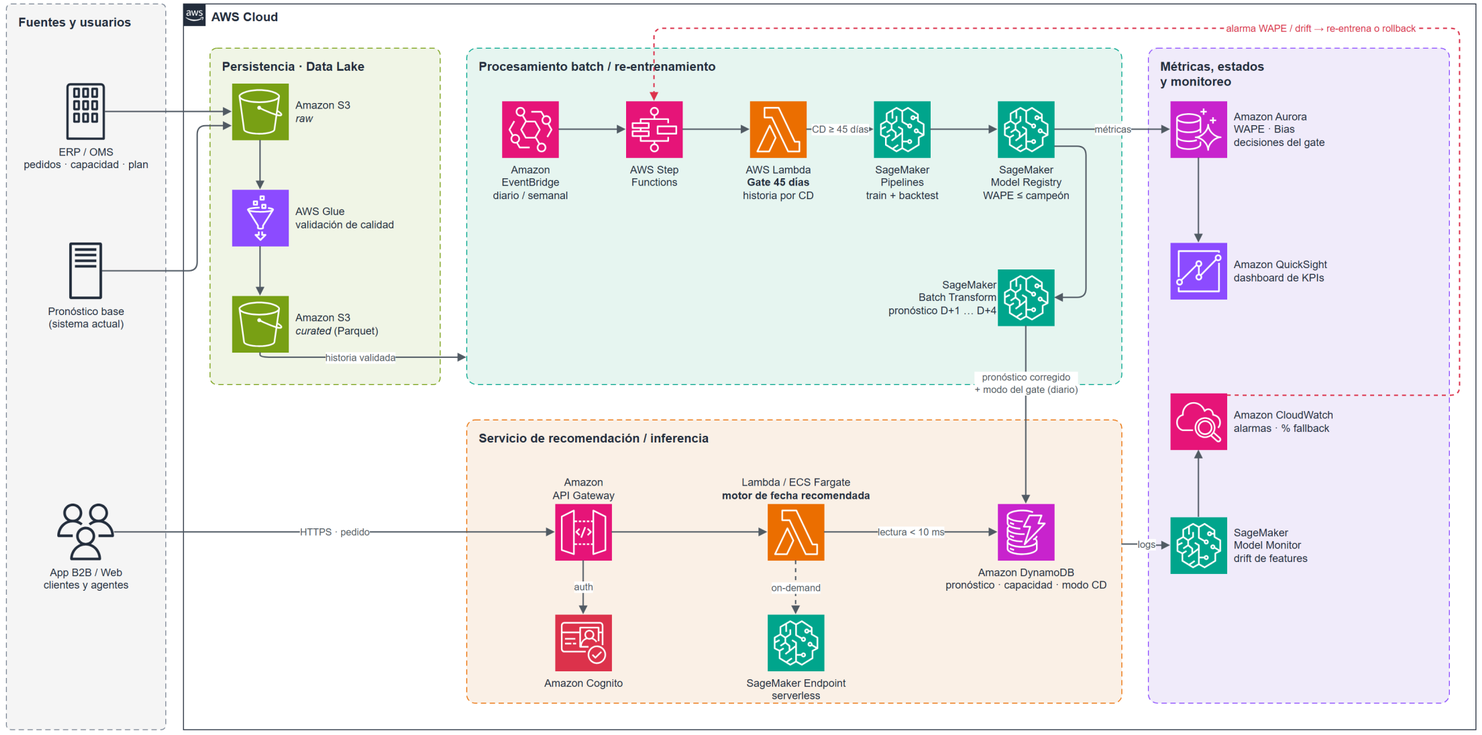
Bajo 21 días el modelo es peor que el fallback. Mejora hasta 45d: 7.0% (28d) → 6.1% (45d), con menos varianza.

## Recomendación

45 días por defecto, configurable por CD; entre 28 y 45 días, el modelo corre en shadow mode.

# Arquitectura AWS: batch, servicio y persistencia

**Arquitectura AWS propuesta** · pronóstico corregido + gate de historia mínima + recomendación de fecha




**Resiliencia:** si no hay pronóstico corregido vigente o el CD tiene < 45 días de historia, DynamoDB sirve el *fallback* (sesgo móvil 14d → pronóstico base). El servicio nunca invoca al modelo en la ruta crítica.

## Batch

Step Functions orquesta gate, entrenamiento y backtest en SageMaker; solo promueve modelos que le ganan al campeón.

## Inferencia

API Gateway + Lambda leen DynamoDB en milisegundos; el modelo no está en la ruta crítica.

## Persistencia

S3 para datos, Aurora para métricas y decisiones del gate, CloudWatch para alarmas.

# Menos fletes de emergencia, flota mejor dimensionada

**−79%**
unidades en flete de emergencia (45.4k → 9.7k)

**86 → 97%**
demanda cubierta con flota reservada

**25 → 5**
camiones de emergencia por semana*

**13 → 0**
días-CD sobre capacidad (slotting)

| Ámbito | KPI | Meta indicativa |
|---|---|---|
| Pronóstico | WAPE y Bias por CD × horizonte, semanal | WAPE < 8%, Bias ±3% |
| Flota | % unidades en emergencia · utilización de flota reservada | −50% vs hoy · > 90% |
| Curva de demanda | Días-CD sobre capacidad · pico/promedio semanal | 0 días · < 1.15 |
| Servicio | OTIF · aceptación de la fecha recomendada | OTIF > 95% |
| Operación ML | % de CD en fallback · drift · latencia p95 | alarmas en CloudWatch |

Backtest de 6 semanas; reserva de flota con el pronóstico D+2. *Supuesto: camión = 300 unidades. · Cristian Carcamo